

به نام خدا دانشگاه تهران



ر دانسکده مهندسی برق و کامپیوتر

# درس شبکههای عصبی و یادگیری عمیق تمرین اول

مهسا راستی نجف آبادی – مینا سیدی	نام و نام خانوادگی
810398084 - 810198393	شماره دانشجویی
14+1.+4.+3	تاریخ ارسال گزارش

## فهرست

1	پاسخ 1. تاثیر تغییر رزولوشن در طبقه بندی در شبکه CNN
1	١-١. دست گرمی
	الف
10	بب
16	
20	د
23	پاسخ ۲ – آشنایی با معماری CNN
23	2-1 لود ديتاست مقاله
24	2-2 انتخاب معماری
26	2-3 توضيح لايههاي مختلف معماري
26	2-4 مقایسه نتایج دو معماری مختلف
29	2-5. مقابسه نتایج استفاده از یفینهسازهای مختلف

## شكلها

5	شكل 1. Libraries شكل 2. شكل
5	شكل 2. لود ديتاست
6	شكل 1. Libraries . شكل 2. لود ديتاست
7	<b>شكل 4.</b> استايل 8x8
	شكل 5. نمايش 10 تصوير رندم در 3 استايل متفاوت
	شكل 6. نمايش 10 تصوير رندم در 3 استايل متفاوتCIFAR10
	<b>شكل 7. تغ</b> يير سايز داده هاى 16x16, 8x8x به 32x32
	<b>شکل 8.</b> تبدیل داده ها از numpy به tensor
12	<b>شكل 9.</b> كلاس ديتاست
13	<b>شکل 9.</b> کلاس دیتاست
13	شكل 11. تعريف معمارى شبكه
14	شكل 12. مدلهاى مورد نياز براى TOVT
	شكل Train . <b>13</b> بر روى GPU
	شكل 14. توابع optimizer و loss
	شكل 15. تابع training
	شكل 16. مدل TOTV و TVTV با داده هاى آموزش 32x32 و تست 32x32
	<b>شكل 17</b> . نتايج مدل TOTV و TVTV با داده هاى آموزش 32x32 و تست 32x32
	شكل 18. مدل TOTV با داده هاى آموزش 32x32 و تست 16x16
	شكل 19. نتايج مدل TOTV با داده هاى آموزش 32x32 و تست 16x16
	شكل <b>20</b> . مدل TOTV با داده هاى آموزش 32x32 و تست 8x8
	شكل <b>21</b> . نتايج مدل TOTV با داده هاى آموزش 32x32 و تست 8x8
	شكل <b>22</b> . مدل TVTV با داده هاى آموزش و تست 16x16
	شکل 23. نتایج مدل TVTV با داده های آموزش و تست 16x16
	شكل <b>24</b> . مدل TVTV با داده هاى آموزش و تست 8x8
	شکل 25. نتایج مدل TVTV با داده های آموزش و تست 8x8

23	<b>شکل I</b> mport . <b>26</b> کردن کتابخانه های مختلف
23	<b>شکل 27</b> . پاک کردن cache در Calab
24	شكل Load . <b>28</b> كردن دادهها
getiten در کلاس My_Datagetiten	شكل <b>29</b> . تعريف توابعlen ،nnit وn
25	<b>شكل 30.</b> معمارى دوم

## جدولها

19		TOVT	استفاده از روش	مقايسه نتايج	جدول 1. ،
22		TVTV ,	استفاده از روش	مقايسه نتايج	جدول 2.
ف29	، معماریهای مختل	، اسازهای مختلف د	استفاده از بهبنه	مقاسه نتابج	حدول 3.

## پاسخ 1. تاثیر تغییر رزولوشن در طبقه بندی در شبکه CNN

۱-۱. دست گرمی

فيلتر اول:

0	1	0
1	1	1
0	1	0

فيلتر دوم:

1	1	1
1	0	1
1	1	1

تصویر اول از کلاس اول:

0	0	0	0
1	1	1	1
1	0	0	1
1	1	1	1

خروجی فیلتر شده با بایاس -2 و تابع فعال سازی رلو:

1	1
1	1

خروجي فيلتر اول



خروجی maxpooling

	1	1	
	5	5	
وم	فيلتر د	وجی ف	خر
	4	5	
max	pooli	— ئى ng	خروج

تصویر دوم از کلاس اول:

1	1	1	0
1	0	1	0
1	1	1	0
0	0	0	1

خروجی فیلتر شده با بایاس -2 و تابع فعال سازی رلو:

2	1
1	1

خروجي فيلتر اول

خروجی maxpooling

6	2
2	1

خروجی فیلتر دوم

خروجی maxpooling

تصویر اول از کلاس دوم:

0	0	0	0
0	1	1	1
0	0	1	0
0	0	0	0

خروجی فیلتر شده با بایاس -2 و تابع فعال سازی رلو:

0	2
0	0

خروجي فيلتر اول



خروجی maxpooling



خروجي فيلتر دوم



خروجی maxpooling

تصویر دوم از کلاس دوم:

0	0	0	1
0	1	0	0
1	1	1	1
0	1	0	0

خروجی فیلتر شده با بایاس -2 و تابع فعال سازی رلو:

	0	0	
	3	1	
ول	فيلتر او	وجی ا	خر
	3	3	

خروجی maxpooling

1	3
2	2

خروجی فیلتر دوم



3 خروجی maxpooling

#### CIFAR10 1.2

Import کردن کتابخانه های مورد نیاز در طول پروژه:

```
!pip install torchmetrics
import torch
import torch.nn as nn
import torch.nn.functional as F
import torchvision
import torchvision.transforms as transforms
import numpy as np
import tensorflow as tf
import matplotlib.pyplot as plt
from datetime import datetime
from keras.datasets import cifar10
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix
from sklearn.metrics import ConfusionMatrixDisplay
import itertools
import time
import torch.utils.data as data_utils
from torchmetrics.classification import BinaryF1Score, BinaryAccuracy, BinaryPrecision
```

شكل Libraries .1

دانلود مجموعه داده از کتابخانه Keras:

شكل 2. لود ديتاست

الف

مجموعه داده ای که دانلود کردیم به صورت دیفالت استایل 32x32 است. پس استایل های 16x16 و 8x8 را به استفاده از 16x16 تهیه میکنیم.

```
16x16 resolution style
[8] x_train16=tf.image.resize(
       images=x_train32,
       size=[16,16],
       method=tf.image.ResizeMethod.NEAREST NEIGHBOR,
       preserve aspect ratio=False,
       antialias=False,
       name=None
       ).numpy()
     np.shape(x_train16)
    x test16=tf.image.resize(
       images=x_test32,
       size=[16,16],
       method=tf.image.ResizeMethod.NEAREST_NEIGHBOR,
       preserve_aspect_ratio=False,
       antialias=False,
       name=None
       ).numpy()
     print(np.shape(x_test16))
```

[-> (10000, 16, 16, 3)

شكل 3. استايل 16x16

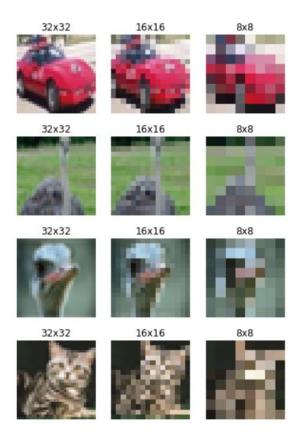
## 8x8 resolution style x\_train8=tf.image.resize( images=x\_train32, size=[8,8], method=tf.image.ResizeMethod.NEAREST\_NEIGHBOR, preserve\_aspect\_ratio=False, antialias=False, name=None ).numpy() np.shape(x train8) x\_test8=tf.image.resize( images=x\_test32, size=[8,8], method=tf.image.ResizeMethod.NEAREST NEIGHBOR, preserve\_aspect\_ratio=False, antialias=False, name=None ).numpy() print(np.shape(x\_test8)) (10000, 16, 16, 3) C→

شكل 4. استايل 8x8

### سپس 10 تصویر به را به صورت رندم در هر سه استایل نمایش میدهیم:

```
A) Showing different resolution styles for 10 random images
     samples=np.random.randint(len(x_train32),size=(10))
     for i,index in zip(range(10),samples):
      ax1=plt.subplot(1,3,1)
      plt.imshow(x_train32[index])
      plt.title("32x32")
      plt.axis('off')
      ax2=plt.subplot(1,3,2)
       plt.imshow(x_train16[index])
      plt.title("16x16")
      plt.axis('off')
       ax3=plt.subplot(1,3,3)
      plt.imshow(x_train8[index])
      plt.title("8x8")
       plt.axis('off')
       plt.show()
```

شكل 5. نمايش 10 تصوير رندم در 3 استايل متفاوت





 ${f CIFAR10}$ شكل 6. نمايش 10 تصوير رندم در 3 استايل متفاوت

ں

دو روش برای تقسیم بندی داده ها به سه دسته آموزش، ارزیابی و تست وجود دارد:

## :Splitting Randomly .1

شما نمی توانید عملکرد پیش بینی یک مدل را با همان داده هایی که برای آموزش استفاده کرده اید ارزیابی کنید. بهتر است مدل را با داده های جدیدی ارزیابی کنید که قبلاً توسط مدل دیده نشده است. تقسیم تصادفی داده ها رایج ترین روش مورد استفاده برای آن ارزیابی بایاس نشده است.

## :Splitting using the temporal component .2

هر زمان که مجموعه داده شامل متغیر تاریخ باشد، و ما بخواهیم چیزی را در آینده پیش بینی کنیم، استفاده از متغیر زمانی روش قابل اعتماد تری برای تقسیم مجموعه داده ها است. از این رو باید از آخرین نمونه ها برای ایجاد مجموعه داده ارزیابی و تست استفاده کنیم.

برای هر دو روش TOTV و TVTV به داده های ارزیابی به 32x32, 16x16, 8x8 نیاز داریم.

8x8 و 8x32 میگیرد، باید داده های 16x16 و 16x16 و 16x16 میگیرد، باید داده های 16x16 و 16x16 و 16x16 را دوباره به سایز 16x16 برسانیم.

```
x train16=tf.image.resize(
  images=x train16,
  size=[32,32],
  method=tf.image.ResizeMethod.NEAREST NEIGHBOR,
  preserve_aspect_ratio=False,
  antialias=False,
  name=None
  ).numpy()
np.shape(x train16)
x_test16=tf.image.resize(
  images=x test16,
  size=[32,32],
  method=tf.image.ResizeMethod.NEAREST_NEIGHBOR,
  preserve aspect ratio=False,
  antialias=False,
  name=None
  ).numpy()
```

```
x train8=tf.image.resize(
  images=x train8,
  size=[32,32],
  method=tf.image.ResizeMethod.NEAREST NEIGHBOR,
  preserve aspect ratio=False,
  antialias=False,
  name=None
  ).numpy()
np.shape(x train8)
x test8=tf.image.resize(
  images=x_test8,
  size=[32,32],
  method=tf.image.ResizeMethod.NEAREST NEIGHBOR,
  preserve aspect ratio=False,
  antialias=False,
  name=None
  ).numpy()
```

**شكل** 7. تغيير سايز داده هاى 16x16, 8x8x به 32x32

سپس داده ها را به Tensor تبدیل میکنیم.

```
changing datatypes from numpy to tensor

#32x32
x_train32=torch.tensor(x_train32, dtype=torch.float32)
y_train32=torch.tensor(y_train32, dtype=torch.float32)
x_test32=torch.tensor(x_test32, dtype=torch.float32)
y_test32=torch.tensor(y_test32, dtype=torch.float32)

#16x16
x_train16=torch.tensor(x_train16, dtype=torch.float32)
y_train16=torch.tensor(y_train32, dtype=torch.float32)
x_test16=torch.tensor(x_test16, dtype=torch.float32)
y_test16=torch.tensor(y_test32, dtype=torch.float32)

#8x8
x_train8=torch.tensor(x_train8, dtype=torch.float32)
y_train8=torch.tensor(y_train32, dtype=torch.float32)
x_test8=torch.tensor(x_test8, dtype=torch.float32)
y_test8=torch.tensor(y_test32, dtype=torch.float32)
```

شکل 8. تبدیل داده ها از numpy به

پس از آن یک کلاس دیتاست تعریف میکنیم تا بتوان با کمک آن داده ها را به Dataloader داده و داده ها را به صورت shuffle شده به ها را به صورت batch به شبکه داد. همچنین برای داده های آموزش داده ها را به صورت شبکه میدهیم.

```
class Dataset():
    def __init__(self, x, y, k):
        self.x = x
        self.yy = np.zeros((self.x.shape[0], k))
        for i in range(self.x.shape[0]):
            self.yy[i][int(y[i])] = 1

    def __len__(self):
        return self.x.shape[0]

    def __getitem__(self, index):
        return self.x[index], self.yy[index]
```

**شكل 9**. كلاس ديتاست

```
K=len(np.unique(y_train32))
#32x32
training_set32=Dataset(x_train32,y_train32,K)
training_generator32 = torch.utils.data.DataLoader(training_set32,batch_size=2000,shuffle=True)

validation_set32=Dataset(x_test32,y_test32,K)
validation_generator32 = torch.utils.data.DataLoader(validation_set32,batch_size=2000,shuffle=False)

# 16x16
training_set16=Dataset(x_train16,y_train16,K)
training_generator16 = torch.utils.data.DataLoader(training_set16,batch_size=2000,shuffle=True)

validation_set16=Dataset(x_test16,y_test16,K)
validation_generator16 = torch.utils.data.DataLoader(validation_set16,batch_size=2000,shuffle=False)

# 8x8
training_set8=Dataset(x_train8,y_train8,K)
training_generator8 = torch.utils.data.DataLoader(training_set8,batch_size=2000,shuffle=True)

validation_set8=Dataset(x_test8,y_test8,K)
validation_generator8 = torch.utils.data.DataLoader(validation_set8,batch_size=2000,shuffle=False)
```

#### شکل 10. دادن دیتاها به dataloader

### سپس شبکه CNN را مطابق با معماری مقاله طراحی میکنیم.

```
class CNN(nn.Module):
  def __init__(self,K):
    super(CNN, self).__init__()
    self.conv1 = nn.Conv2d(3,32,kernel_size=3)
    self.conv2 = nn.Conv2d(32,32,kernel_size=3)
    self.conv3 = nn.Conv2d(32,32,kernel_size=3)
    self.conv4 = nn.Conv2d(32,64,kernel_size=3)
    self.conv5 = nn.Conv2d(64,64,kernel_size=3)
    self.conv6 = nn.Conv2d(64,64,kernel_size=3)
    self.maxpool1=nn.MaxPool2d((2,2))
    self.maxpool2=nn.MaxPool2d((2,2))
    self.lin1 = nn.Linear(64 * 3 * 3, 512)
    self.lin2 = nn.Linear(512, K)
    self.drp1 = nn.Dropout(p=0.25)
    self.drp2 = nn.Dropout(p=0.5)
  def forward(self,x):
    x = F.relu(self.conv1(x))
    x = F.relu(self.conv2(x))
    x = F.relu(self.conv3(x))
    x = self.maxpool1(x)
    x = self.drp1(x)#
    x = F.relu(self.conv4(x))
    x = F.relu(self.conv5(x))
    x = F.relu(self.conv6(x))
    x = self.maxpool2(x)
    x = self.drp1(x)
    x = x.contiguous().view(-1,64 * 3 * 3)
    x = F.relu(self.lin1(x))
    x = self.drp2(x)
    x = self.lin2(x)
    return x
```

شكل 11. تعريف معماري شبكه

#### مدل های مجزا برای حالات داده های تست و ترین (32x32, 16x16, 8x8) تعریف میکنیم.

```
Defining needed models for both TVTV and TOTV methods

cifar10_model=CNN(K)
cifar10_model16=CNN(K)
cifar10_model8=CNN(K)
cifar10_model3216=CNN(K)
cifar10_model328=CNN(K)
```

شكل 12. مدلهای مورد نیاز برای TOVT

مدل ها را روی gpu ترین میکنیم.

```
Use gpu for Trainnig

use_cuda = torch.cuda.is_available()
device = torch.device("cuda:0" if use_cuda else "cpu")
torch.backends.cudnn.benchmark = True
print(device)
cifar10_model.to(device)
cifar10_model16.to(device)
cifar10_model3216.to(device)
cifar10_model3216.to(device)
cifar10_model328.to(device)
cifar10_model328.to(device)

cuda:0

CNN(
    (conv1): conv2d(3, 32, kernel_size=(3, 3), stride=(1, 1))
    (conv2): conv2d(32, 32, kernel_size=(3, 3), stride=(1, 1))
    (conv2): conv2d(32, 32, kernel_size=(3, 3), stride=(1, 1))
    (conv3): conv2d(32, 32, kernel_size=(3, 3), stride=(1, 1))
    (conv3): conv2d(32, 64, kernel_size=(3, 3), stride=(1, 1))
    (conv6): conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1))
    (conv6): conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1))
    (maxpool1): MaxPool2d(kernel_size=(2, 2), stride=(2, 2), padding=0, dilation=1, ceil_mode=False)
    (lin1): Linear(in_features=512, out_features=512, bias=True)
    (lin2): Linear(in_features=512, out_features=512, bias=True)
    (drp1): Dropout(p=0.25, inplace=False)
    (drp2): Dropout(p=0.5, inplace=False)
}
```

شكل Train .13 بر روى

توابع optimization و loss را تعريف ميكنيم.

```
Optimization and criterion for both TVTV and TOTV methods

criterion = nn.CrossEntropyLoss()
optimizer = torch.optim.Adam(cifar10_model.parameters(),lr=0.001)
optimizer16 = torch.optim.Adam(cifar10_model16.parameters(),lr=0.001)
optimizer8 = torch.optim.Adam(cifar10_model8.parameters(),lr=0.001)
optimizer3216 = torch.optim.Adam(cifar10_model3216.parameters(),lr=0.001)
optimizer328 = torch.optim.Adam(cifar10_model328.parameters(),lr=0.001)
metricF1=BinaryF1Score()
metricAcc=BinaryAccuracy()
metricPre=BinaryPrecision()
softmax = nn.Softmax(dim=1)
```

شكل 14. توابع optimizer و

### تابع training مدل را تعریف میکنیم.

```
Training the model

item train_loop(model, criterion, optimizer, train_loader, valid_loader, epochs):
    train_losses=np.zeros(epochs)
    valid_losses=np.zeros(epochs)
    Accuracy=np.zeros(epochs)

for i in range(epochs):
    t0=datetime.now()
    train_loss=[]
    valid_loss=[]
    f1 = []
    accuracy = []
    precision=[]
```

```
model.train()
for datas, targets in train_loader:
  datas, targets= datas.to(device), targets.to(device)
  datas=torch.permute(datas,(0,3,1,2))
  optimizer.zero_grad()
  outputs=model(datas)
  loss=criterion(outputs, targets)
  loss.backward()
  optimizer.step()
  train loss.append(loss.item())
train_loss=np.mean(train_loss)
with torch.no_grad():
  model.eval()
  for datas, targets in valid_loader:
   datas, targets= datas.to(device), targets.to(device)
   datas=torch.permute(datas,(0,3,1,2))
    outputs=model(datas)
    outputs = softmax(outputs)
    loss=criterion(outputs, targets)
    valid_loss.append(loss.item())
    f1.append(metricF1(outputs.cpu(),targets.cpu()))
    accuracy.append(metricAcc(outputs.cpu(),targets.cpu()))
    precision.append(metricPre(outputs.cpu(),targets.cpu()))
valid_loss=np.mean(valid_loss)
f1=np.mean(f1)
accuracy=np.mean(accuracy)
precisionn=np.mean(precision)
```

```
train_losses[i]=train_loss
valid_losses[i]=valid_loss
Accuracy[i]=accuracy

delta_t=datetime.now()-t0

print(f'epoch {i+1}/{epochs}, train loss: {train_loss:.4f}, \
    validation loss: {valid_loss:.4f}, duration: {delta_t}')
print(f'epoch {i+1}/{epochs}, f1: {f1:.4f}, \
    accuracy: {accuracy:.4f}, precision: {precisionn:.4f}')

return train_losses, valid_losses, Accuracy
```

شكل 15. تابع training

ج روش TOTV

```
TOTV and TVTV 32x32

(variable) valid_losses32: ndarray

train_losses32, valid_losses32, accuracy32 = train_loop(cifar10_model, criterion, optimizer, training_generator32, validation_generator32, epochs=75)
```

## 32x32 و تست TVTV و TVTV با داده های آموزش 32x32 و تست TVTV

32x32 و تست TVTV و TVTV با داده های آموزش TVTV و تست TVTV



### شكل 18. مدل TOTV با داده هاى آموزش 32x32 و تست TOTV

```
accuracy: 0.9000, accuracy: 0.9025,
epoch 3/100, f1: 0.2283,
epoch 4/100, f1: 0.2397,
epoch 5/100, f1: 0.2595,
                                                                                                                                                                                                                    precision: 0.6413
precision: 0.6655
precision: 0.7190
                                                                                                                    accuracy: 0.9061,
accuracy: 0.9073,
                                                                                                                     accuracy: 0.9096,
   poch 5/100, f1: 0.2595,
poch 6/100, f1: 0.3525,
poch 7/100, f1: 0.3944,
poch 8/100, f1: 0.4100,
poch 9/100, f1: 0.4405,
poch 10/100, f1: 0.4367,
                                                                                                                     accuracy: 0.9156,
accuracy: 0.9163,
accuracy: 0.9107,
                                                                                                                                                                                                                    precision: 0.6806
precision: 0.6644
precision: 0.5915
 epoch 11/100, f1: 6.4307,
epoch 11/100, f1: 0.4737,
epoch 12/100, f1: 0.4791,
epoch 13/100, f1: 0.4531,
epoch 14/100, f1: 0.4544,
epoch 15/100, f1: 0.4717,
epoch 16/100, f1: 0.5019,
                                                                                                                      accuracy: 0.9195,
accuracy: 0.9206,
accuracy: 0.9114,
                                                                                                                                                                                                                       precision: 0.6840
precision: 0.6962
precision: 0.5921
                                                                                                                         accuracy: 0.9185,
                                                                                                                                                                                                                        precision: 0.6456
  epoch 16/100, f1: 0.3613,
epoch 18/100, f1: 0.4653,
epoch 18/100, f1: 0.4708,
epoch 20/100, f1: 0.4718,
epoch 20/100, f1: 0.4839,
epoch 21/100, f1: 0.482,
                                                                                                                        accuracy: 0.9097, accuracy: 0.9135, accuracy: 0.9174,
                                                                                                                                                                                                                       precision: 0.5682
precision: 0.6000
precision: 0.6351
  ppoch 21/100, f1: 0.4962,
epoch 22/100, f1: 0.4724,
epoch 23/100, f1: 0.5018,
epoch 24/100, f1: 0.4940,
epoch 25/100, f1: 0.5123,
epoch 26/100, f1: 0.4528,
                                                                                                                        accuracy: 0.9140, accuracy: 0.9168, accuracy: 0.9065,
                                                                                                                                                                                                                        precision: 0.5997
precision: 0.6196
precision: 0.5462
epoch 27/100, f1: 0.4528,
epoch 27/100, f1: 0.4635,
epoch 28/100, f1: 0.4523,
epoch 29/100, f1: 0.4854,
epoch 30/100, f1: 0.4764,
epoch 31/100, f1: 0.4764,
                                                                                                                                                                                                                         precision: 0.5435
                                                                                                                        accuracy: 0.9111, accuracy: 0.9071, accuracy: 0.9092,
                                                                                                                                                                                                                       precision: 0.5784
precision: 0.5469
                                                                                                                                                                                                                        precision: 0.5626
                                                                                                                      accuracy: 0.8965, accuracy: 0.9157, accuracy: 0.9091,
     ooch 37/100, f1: 0.5026,
ooch 38/100, f1: 0.4124,
ooch 39/100, f1: 0.4334,
                                                                                                                      accuracy: 0.9141, accuracy: 0.8942, accuracy: 0.8979,
                                                                                                                                                                                                                     precision: 0.5970
precision: 0.4637
precision: 0.4868
      och 40/100, f1: 0.4595,
och 41/100, f1: 0.4709,
och 42/100, f1: 0.4568,
                                                                                                                                                                                                                     precision: 0.5241
precision: 0.5314
precision: 0.5255
      och 43/100, f1: 0.4590,
och 44/100, f1: 0.4417,
och 45/100, f1: 0.4635,
                                                                                                                                                                                                                    precision: 0.5175
precision: 0.4966
precision: 0.5306
       och 46/100, f1: 0.4486,
och 47/100, f1: 0.4343,
och 48/100, f1: 0.4391,
                                                                                                                                                                                                                    precision: 0.5109
precision: 0.4897
precision: 0.4954
      och 48/100, f1: 0.4391,
och 49/100, f1: 0.4425,
och 50/100, f1: 0.4495,
och 51/100, f1: 0.3963,
och 52/100, f1: 0.4282,
och 53/100, f1: 0.4545,
                                                                                                                                                                                                                     precision: 0.4362
precision: 0.4751
precision: 0.5116
      och 54/100, f1: 0.3828,
och 55/100, f1: 0.3977,
och 56/100, f1: 0.4529,
                                                                                                                      accuracy: 0.8872, accuracy: 0.8898, accuracy: 0.9012,
                                                                                                                                                                                                                    precision: 0.4227
precision: 0.4387
precision: 0.5073
                  57/100, f1: 0.4049,
58/100, f1: 0.4621,
59/100, f1: 0.4403,
                                                                                                                                                                                                                     precision: 0.4521
precision: 0.5183
precision: 0.4932
     ooch 60/100, f1: 0.4018,
ooch 61/100, f1: 0.4332,
ooch 62/100, f1: 0.4475,
                                                                                                                      accuracy: 0.8912, accuracy: 0.8965, accuracy: 0.9000,
                                                                                                                                                                                                                     precision: 0.4462
precision: 0.4787
precision: 0.4999
     ooch 63/100, f1: 0.4022,
ooch 64/100, f1: 0.4315,
ooch 65/100, f1: 0.4396,
                                                                                                                                                                                                                     precision: 0.4402
precision: 0.4763
precision: 0.4835
                                                                                                                                                                                                                     precision: 0.4508
epoch 67/100, f1: 0.4601,
epoch 68/100, f1: 0.4746,
epoch 69/100, f1: 0.4190,
epoch 70/100, f1: 0.4324,
epoch 71/100, f1: 0.4324,
epoch 72/100, f1: 0.4069,
epoch 73/100, f1: 0.4263,
epoch 73/100, f1: 0.4263,
epoch 73/100, f1: 0.4488,
                                                                                                                          accuracy: 0.9053, accuracy: 0.8927,
                                                                                                                                                                                                                       precision: 0.5329
precision: 0.4569
                                                                                                                                                                                                                       precision: 0.4369
precision: 0.4734
precision: 0.4961
precision: 0.4397
precision: 0.4701
precision: 0.4952
                                                                                                                          accuracy: 0.8896,
```

شكل 19. نتايج مدل TOTV با داده هاى آموزش 32x32 و تست 16x16

```
TOTV 32x32-> 8x8

Loading...

train_losses_32_, valid_losses_8, accuracy3 = train_loop(cifar10_model328, criterion, optimizer328, training_generator32, validation_generator8, epochs=75)
```

### شكل 20. مدل TOTV با داده هاى آموزش 32x32 و تست

```
epoch 36/100, f1: 0.2633, epoch 37/100, f1: 0.2597,
                                                                                 precision: 0.2911
                                                                                precision: 0.2842
epoch 39/100, f1: 0.2395, epoch 40/100, f1: 0.2717,
                                             accuracy: 0.8584,
                                            accuracy: 0.8651,
                                             accuracy: 0.8654,
                                                                                 precision: 0.2959
epoch 43/100, f1: 0.2627, epoch 44/100, f1: 0.2440,
                                            accuracy: 0.8634,
                                                                                precision: 0.2853
epoch 46/100, f1: 0.2452, epoch 47/100, f1: 0.2515,
                                                                                 precision: 0.2604
                                            accuracy: 0.8596,
                                                                                precision: 0.2693
epoch 49/100, f1: 0.2398, epoch 50/100, f1: 0.2386,
                                            accuracy: 0.8580,
                                                                                precision: 0.2572
epoch 52/100, f1: 0.2333, epoch 53/100, f1: 0.2457,
                                            accuracy: 0.8585,
                                                                                precision: 0.2632
epoch 54/100, f1: 0.2483,
                                            accuracy: 0.8593,
epoch 55/100, f1: 0.2530, epoch 56/100, f1: 0.2786,
                                            accuracy: 0.8681,
                                                                                 precision: 0.3076
epoch 57/100, f1: 0.2409,
                                                                                precision: 0.2551
                                            accuracy: 0.8562,
epoch 59/100, f1: 0.2428, epoch 60/100, f1: 0.2429,
                                             accuracy: 0.8575,
                                                                                precision: 0.2592
epoch 61/100, f1: 0.2586,
                                             accuracy: 0.8599,
epoch 63/100, f1: 0.2353,
                                             accuracy: 0.8549,
                                                                                 precision: 0.2487
epoch 64/100, f1: 0.2335,
                                             accuracy: 0.8552,
                                                                                precision: 0.2480
                                             accuracy: 0.8578,
                                                                                 precision: 0.2650
                                                                                 precision: 0.2541
```

شكل 21. نتايج مدل TOTV با داده هاى آموزش 32x32 و تست 8x8

## ${f TOVT}$ جدول 1. مقایسه نتایج استفاده از روش

CIFAR10	TOTV		
Dataset resolution	Accuracy	Precision	F1 score
32x32	95.68%	82.45%	76.98%
16x16	90.51%	53.10%	48.02%
8x8	86.06%	27.9%	26.28%

3

## روش TVTV:

#### TVTV 16x16

[33] train\_losses16, valid\_losses16, accuracy16 = train\_loop(cifar10\_model16, criterion, optimizer16, training\_generator16,validation\_generator16, epochs=100)

## **شكل 22**. مدل **TVTV** با داده هاى آموزش و تست **TVTV**

epoch 1/100, f. epoch 2/100, f. epoch 3/100, f. epoch 3/100, f. epoch 6/100, f. epoch 6/100, f. epoch 6/100, f. epoch 8/100, f. epoch 9/100, f. epoch 10/100, epoch 11/100, epoch 12/100, epoch 13/100, epoch 15/100, epoch 15/100, epoch 15/100, epoch 15/100, epoch 15/100, epoch 18/100, epoch 18/100, epoch 18/100, epoch 18/100, epoch 19/100, epoch 19/100, epoch 19/100, epoch 19/100,			
epoch 1/100, fi	1: 0.0018,	accuracy: 0.8999,	precision: 0.3690
epoch 2/100, f1	1: 0.1442,	accuracy: 0.9024, accuracy: 0.9078,	precision: 0.5869
epoch 3/100, fo	1: 0.2510.	accuracy: 0.9078.	precision: 0.6703
enoch 4/100, fr	1: 0.3499	accuracy: 0.9112,	precision: 0.6536
apach =/100, fr	1. 0.3433,	accuracy: 0.9157,	precision: 0.7167
epoch 5/100, 11	1. 0.3801,	accuracy: 0.9197,	precision. 0.7107
epocii 6/100, 11	1: 0.4538,	accuracy: 0.9200,	precision: 0.7158 precision: 0.7330 precision: 0.7698
epocn //100, fi	1: 0.45/4,	accuracy: 0.9211,	precision: 0.7330
epoch 8/100, 13	1: 0.4932,	accuracy: 0.9157, accuracy: 0.9200, accuracy: 0.9211, accuracy: 0.9211, accuracy: 0.9254, accuracy: 0.9263, accuracy: 0.9263, accuracy: 0.9365, accuracy: 0.9316, accuracy: 0.9316, accuracy: 0.9318, accuracy: 0.9322, accuracy: 0.9322, accuracy: 0.9322, accuracy: 0.9324, accuracy: 0.9324, accuracy: 0.9324, accuracy: 0.9324, accuracy: 0.9327,	precision: 0.7698
epoch 9/100, fi	1: 0.5183,	accuracy: 0.9263,	precision: 0.7484
epoch 10/100,	f1: 0.5140,	accuracy: 0.9249,	precision: 0.7283
epoch 11/100, 1	f1: 0.5490,	accuracy: 0.9305,	precision: 0.7817
epoch 12/100.	f1: 0.5735.	accuracy: 0.9310.	precision: 0.7503
epoch 13/100.	f1: 0.5649.	accuracy: 0.9315.	precision: 0.7745
enoch 14/100	F1 · 0 5783	accuracy: 0 9328	precision: 0.7768 precision: 0.7557
opoch 15/100,	F1. 0.5705,	accuracy: 0.5520,	precision: 0.7700
epoch 16/100,	61. 0.5641,	accuracy. 0.9322,	precision: 0.7993
epocii 16/100,	11: 0.3709,	accuracy: 0.9332,	precision: 0.7720
epocn 1//100,	11: 0.6051,	accuracy: 0.9351,	
epoch 18/100,	f1: 0.5955,	accuracy: 0.9342,	precision: 0.7727
epoch 19/100, 1 epoch 20/100, 1	f1: 0.6046,	accuracy: 0.9349,	precision: 0.7706
		accuracy: 0.9371,	precision: 0.7975
epoch 21/100,	f1: 0.6231,	accuracy: 0.9376,	precision: 0.7872
epoch 22/100, 1	f1: 0.6288,	accuracy: 0.9383,	precision: 0.7884 precision: 0.7948
epoch 23/100,	f1: 0.6306,	accuracy: 0.9388,	precision: 0.7948
epoch 24/100	f1: 0.6329.	accuracy: 0.9389.	
enoch 25/100	f1: 0.6452.	accuracy: 0.9401.	precision: 0.7930 precision: 0.7912
enoch 26/100	F1 0 6234	accuracy: 0.3467	precision: 0.7695
epoch 20/100, 1 epoch 21/100, 1 epoch 22/100, 1 epoch 23/100, 1 epoch 25/100, 1 epoch 26/100, 1 epoch 27/100, 1 epoch 28/100, 1	F1: 0:0234,	accuracy: 0.9376, accuracy: 0.9383, accuracy: 0.9388, accuracy: 0.9389, accuracy: 0.9367, accuracy: 0.9467, accuracy: 0.9402, accuracy: 0.9404, accuracy: 0.9404, accuracy: 0.9404, accuracy: 0.9404,	precision. 0.7033
epoch 27/100, 1	F1. 0.0480,	accuracy: 0.9407,	precision: 0.7974
epoch 28/100, 1 epoch 29/100, 1 epoch 30/100, 1 epoch 31/100, 1 epoch 32/100, 1	ri: 0.6481,	accuracy: 0.9402,	precision: 0.7879
epoch 29/100, 1	ri: 0.6520,	accuracy: 0.9404,	precision: 0.7832
epoch 30/100,	f1: 0.6497,	accuracy: 0.9404,	precision: 0.7873
epoch 31/100, 1	f1: 0.6669,	accuracy: 0.9423,	precision: 0.7895
epoch 32/100, 1	f1: 0.6613,	accuracy: 0.9420,	precision: 0.7943
epoch 33/100, f	1. 0 6576	accuracy: 0.9417,	precision: 0.7970
opoch 34/100, f	1. 0.0570,	accuracy: 0.941/, accuracy: 0.9429, accuracy: 0.9424, accuracy: 0.9422, accuracy: 0.9422, accuracy: 0.9433, accuracy: 0.9431,	precision. 0.7570
epoch 34/100, T	1: 0.6629,	accuracy: 0.9429,	precision: 0.8083
epocn 35/100, T	1: 0.6666,	accuracy: 0.9424,	precision: 0.7911 precision: 0.7859 precision: 0.7844
epoch 36/100, f	1: 0.66/9,	accuracy: 0.9422,	precision: 0.7859
epoch 37/100, f	1: 0.6685,	accuracy: 0.9422,	precision: 0.7844
epoch 38/100, f	1: 0.6704,	accuracy: 0.9432,	precision: 0.7995
epoch 39/100, f	1: 0.6724,	accuracy: 0.9431,	precision: 0.7925
epoch 40/100, f	1: 0.6746.	accuracy: 0.9436.	precision: 0.7971
enoch 41/100, f	1: 0.6730.	accuracy: 0.9434,	precision: 0.7963
enoch 42/100 f	1. 0 6707	accuracy: 0.9427,	precision: 0.7877
opoch 42/100, f	1. 0.6707,	accuracy: 0.9440,	precision, a 7000
epocii 45/100, 1	1. 0.0023,	accuracy. 6.9446,	precision: 0.7889
epocii 44/100, i	1: 0.0838,	accuracy: 0.9438,	precision: 0.7818 precision: 0.7986 precision: 0.7912
epocn 45/100, †	1: 0.6863,	accuracy: 0.9450,	precision: 0.7986
epoch 46/100, f	1: 0.6875,	accuracy: 0.9438, accuracy: 0.9450, accuracy: 0.9447, accuracy: 0.9447, accuracy: 0.9431, accuracy: 0.9431,	precision: 0.7912
epoch 47/100, f	1: 0.6780,	accuracy: 0.9431,	precision: 0.7804
epoch 48/100, f	1: 0.6900,	accuracy: 0.9447,	precision: 0.7846
epoch 49/100, f	1: 0.6876,	accuracy: 0.9443,	precision: 0.7834
epoch 50/100, f	1: 0.6835,	accuracy: 0.9448,	precision: 0.8007
epoch 51/100 f	1: 0.6876.	accuracy: 0.9454.	precision: 0.8029
epoch 52/100 f	1: 0.6845.	accuracy: 0.9451.	nrecision: 0.8049
enoch 53/100, f	1: 0.6859	accuracy: 0.9445	precision: 0 7904
enoch 54/100, 1	1. 0.6054	accuracy: 0.5445;	precision: 0.7504
opoch 55/100, 1	1. 0.0034,	accuracy, 0.9432,	precision: 0.7904 precision: 0.8046 precision: 0.7905
epoch 55/100, T	1. 0.0047,	accuracy: 0.9448, accuracy: 0.9451, accuracy: 0.9451, accuracy: 0.9452, accuracy: 0.9452, accuracy: 0.9444, accuracy: 0.9458, accuracy: 0.9454, accuracy: 0.9458,	precision: 0.7905
epocn 56/100, f	1: 0.6929,	accuracy: 0.9458,	precision: 0.7996
epoch 57/100, f	1: 0.6919,	accuracy: 0.9454,	precision: 0.7947
epoch 58/100, f	1: 0.6864,	accuracy: 0.9448,	precision: 0.7956
epoch 59/100, f	1: 0.6871,	accuracy: 0.9449,	precision: 0.7960
epoch 60/100, f	1: 0.6928,	accuracy: 0.9455,	precision: 0.7946
epoch 61/100, f	1: 0.6977,	accuracy: 0.9458,	precision: 0.7890
epoch 62/100, f	1: 0.6871,	accuracy: 0.9445,	precision: 0.7883
epoch 63/100. f	1: 0.6933,	accuracy: 0.9445, accuracy: 0.9454,	precision: 0.7917
epoch 33/100, f epoch 34/100, f epoch 35/100, f epoch 36/100, f epoch 37/100, f epoch 39/100, f epoch 49/100, f epoch 44/100, f epoch 44/100, f epoch 44/100, f epoch 45/100, f epoch 46/100, f epoch 46/100, f epoch 46/100, f epoch 36/100, f epoch 59/100, f			
epoch 64/100, f epoch 65/100, f epoch 66/100, f epoch 66/100, f epoch 69/100, f epoch 70/100, f epoch 70/100, f epoch 72/100, f epoch 72/100, f epoch 73/100, f epoch 75/100, f	1 • 0 6024	accuracy: 0 0453	procision: A 7006
epoch 65/100, 1	1. 0.0924,	accuracy: 0.9453,	precision: 0.7906 precision: 0.7849 precision: 0.7937 precision: 0.7843 precision: 0.7920
epoch 65/100, f	1: 0.68/3,	accuracy: 0.9444,	precision: 0.7849
epoch 66/100, f	1: 0.6988,	accuracy: 0.9462,	precision: 0.7937
epoch 67/100, f	1: 0.6967,	accuracy: 0.9454,	precision: 0.7843
epoch 68/100, f	1: 0.7006,	accuracy: 0.9462, accuracy: 0.9454, accuracy: 0.9463,	precision: 0.7920
epoch 69/100, f	1: 0.6960,	accuracy: 0.9453, accuracy: 0.9456, accuracy: 0.9452,	precision: 0./884
epoch 70/100, f	1: 0.6929,	accuracy: 0.9452,	precision: 0.7889
epoch 71/100. f	1: 0.6989,	accuracy: 0.9459,	precision: 0.7888
enoch 72/100 f	1: 0.6981.	accuracy: 0.9459,	precision: 0.7906
enoch 72/100, 1	1. 0 70/15	accuracy: 0.9469,	precision: 0.7300
epoch 73/100, 1	1: 0.7043,	accuracy: 0.9459,	precision: 0.7944 precision: 0.7833
opoch 75/100, 1	1. 0.0991,		precision: 0.7833
epocn 75/100, f	1: 0.6961,	accuracy: 0.9454,	precision: 0.7854

16x16 با داده های آموزش و تست TVTV با داده های آموزش و تست

#### TVTV 8x8

train\_losses8, valid\_losses8, accuracy8 = train\_loop(cifar10\_model8, criterion, optimizer8, training\_generator8,validation\_generator8, epochs=100)

## **8x8** مدل **TVTV** با داده های آموزش و تست

epoch	1/100, f	1: 0.0002,	accuracy:	0.9000,	precision: 0.2000
epoch	2/100, f	1: 0.0902, 1: 0.0279, 1: 0.1299, 1: 0.2380, 1: 0.2087, 1: 0.2954, 1: 0.3306,	accuracy: accuracy: accuracy: accuracy: accuracy: accuracy: accuracy: accuracy:	0.9005,	precision: 0.6119
epoch	3/100, f	1: 0.1299,	accuracy:	0.9013,	precision: 0.5496
epoch	4/100, †	1: 0.2380,	accuracy:	0.9062,	precision: 0.6351
opoch	6/100, I	1. 0.2007,	accuracy:	0.9009, a aas	precision: 0.6351 precision: 0.6929 precision: 0.6868
epoch	7/100, f	1: 0.2954.	accuracy:	0.9101.	precision: 0.6821
epoch	8/100, f	1: 0.3306,	accuracy:	0.9121,	precision: 0.6940
epoch	9/100, f	1. 0.22,			precision: 0.7141
onach	10/100	£1. 0 3E00	accuracy: accuracy:	0.9144,	precision: 0.7129
epoch	11/100,	11. 0.3999, f1: 0.3900, f1: 0.4180, f1: 0.4019, f1: 0.4580, f1: 0.4364, f1: 0.4484,	accuracy:	0.9159,	precision: 0.7089
epoch	12/100,	f1: 0.4180,	accuracy:	0.9157,	precision: 0.6755
epoch	13/100,	f1: 0.4019,	accuracy: accuracy:	0.0001	precision: 0.7311 precision: 0.7116
enoch	15/100,	f1: 0.4364.	accuracy:	0.9201,	precision: 0.7133
epoch	16/100,	f1: 0.4484,	accuracy:	0.9205,	precision: 0.7311
epoch	17/100,	f1: 0.4753,	accuracy:	0.9217,	precision: 0.7200
epoch	18/100,	f1: 0.4569,	accuracy:	0.9217,	precision: 0.7447
epoch	19/100,	f1: 0.4782,	accuracy:	0.9224,	precision: 0.7290
epoch	20/100,	f1: 0.4753, f1: 0.4569, f1: 0.4782, f1: 0.4730, f1: 0.4855, f1: 0.4965,	accuracy: accuracy: accuracy: accuracy:	0.9220,	precision: 0.7298 precision: 0.7454
epoch	21/100,	T1: 0.4855, f1: 0.4855	accuracy	0.9237,	precision: 0.7391
epoch	23/100,	f1: 0.5044,	accuracy:	0.9242,	precision: 0.7344
epoch	24/100,	f1: 0.5035,	accuracy:		precision: 0.7310
epoch	25/100,		accuracy:	0.9252.	precision: 0.7403
epoch	26/100,	f1: 0.5049,	accuracy:	0.9250,	precision: 0.7433
epoch	27/100,	f1: 0.5187,	accuracy: accuracy: accuracy: accuracy:	0.9263,	precision: 0.7475
epoch	28/100,	f1: 0.5240,	accuracy:	0.9262,	precision: 0.7372
epoch	29/100,	T1: 0.5181,	accuracy: accuracy:	0.9259,	precision: 0.7401 precision: 0.7251
epoch	31/100,	f1: 0.5241,	accuracy:	0.9264.	precision: 0.7231
epoch	32/100,	f1: 0.5374,	accuracy:		precision: 0.7358
epoch	33/100,	f1: 0.5363,	accuracy:		precision: 0.7456
epoch	34/100,	11: 0.5090, f1: 0.5049, f1: 0.5187, f1: 0.5240, f1: 0.5241, f1: 0.5381, f1: 0.5381, f1: 0.5374, f1: 0.5363, f1: 0.5442,	accuracy:	0.9278,	precision: 0.7388
epoch	35/100, ·	f1: 0.5444, f1: 0.5397, f1: 0.5434, f1: 0.5463, f1: 0.5512, f1: 0.5519, f1: 0.5477, f1: 0.5635, f1: 0.5631, f1: 0.5622,	accuracy:	0.9271,	precision: 0.7253
epoch	36/100,	f1: 0.5397,	accuracy:	0.9272,	precision: 0.7340
epoch	37/100,	f1: 0.5434,	accuracy:		precision: 0.7446
epoch	38/100,	f1: 0.5463,	accuracy:	0.9279,	precision: 0.7359
epoch	10/100, T	F1: 0.5512, F1: 0.5586	accuracy:	0.9279, 0.9278, 0.9279,	precision: 0.7294 precision: 0.7190
enoch	41/100.	f1: 0.5519.	accuracy:	0.9279.	precision: 0.7289
epoch	42/100,	f1: 0.5477,	accuracy:	0.9278,	precision: 0.7336
epoch	43/100,	f1: 0.5635,	accuracy:	0.9293,	precision: 0.7369
epoch	44/100,	f1: 0.5531,	accuracy:	0.9279,	precision: 0.7281
epoch	45/100,	f1: 0.5622,	accuracy:		precision: 0.7203
epoch	46/100,		accuracy:	0.9277,	precision: 0.7264
epoch	4//100,	F1: 0.5591, F1: 0.5650	accuracy:	0.92/8,	precision: 0.7186 precision: 0.7241
epoch	49/100.	f1: 0.5635.	accuracy:	0.9289.	precision: 0.7305
epoch	50/100,	f1: 0.5702,	accuracy:	0.9296,	precision: 0.7305 precision: 0.7314
epoch	51/100,	f1: 0.5580,	accuracy:	0.9286,	precision: 0.7318
epoch	52/100,	f1: 0.5626,	accuracy:	0.9288,	precision: 0.7293
epoch	53/100,	f1: 0.5626,	accuracy:		precision: 0.7174
epoch	54/100,	f1: 0.5629,	accuracy:	0.9286,	precision: 0.7262
epoch	56/100, T	F1: 0.5705, F1: 0.5655	accuracy:	0.9289, 0.9289	precision: 0.7199 precision: 0.7315
epoch	57/100.	11: 0.5629, fl: 0.5705, fl: 0.5655, fl: 0.5643, fl: 0.5615, fl: 0.5703, fl: 0.5706,	accuracy:	0.9288.	precision: 0.7313
epoch	58/100,	f1: 0.5615,	accuracy:	0.9281,	precision: 0.7194
epoch	59/100,	f1: 0.5703,	accuracy:	0.9290,	precision: 0.7229
epoch	60/100,	f1: 0.5660,	accuracy:	0.9287,	precision: 0.7226
epoch	61/100,	f1: 0.5777,	accuracy:		precision: 0.7170
epoch	62/100,	f1: 0.5616,	accuracy:		precision: 0.7176
epoch	64/100,	F1: 0.5749,	accuracy:	0.9296, 0.9285	precision: 0.7248 precision: 0.7126
epoch	65/100.	f1: 0.5562.	accuracy:	0.9271,	precision: 0.7111
epoch	66/100	f1: 0.5695,	accuracy:	0.9281,	precision: 0.7093
epoch	67/100,	f1: 0.5801,	accuracy:	0.9296,	precision: 0.7180
epoch	68/100,	11: 0.5777, f1: 0.5616, f1: 0.5749, f1: 0.5723, f1: 0.5562, f1: 0.5695, f1: 0.5801, f1: 0.5744,	accuracy:	0.9295,	precision: 0.7242
epoch (	69/100, 1	1: 0.5669,	accuracy	: 0.9284,	precision: 0.7171
epoch :	70/100, i	1: 0.5692,	accuracy	: 0.9280,	precision: 0.7090
epoch :	/1/100, t	1: 0.5754,	accuracy	r: 0.9285,	precision: 0.7083
	72/100, 1	1. 0.0093,	accuracy	. 0.9283,	precision: 0.7121
enoch :	73/100 -	1: 0.5761	accuracy	. 0 9288	nrecision: 0 7122
epoch :	73/100, f	f1: 0.5761, f1: 0.5777	accuracy	. 0.9288,	precision: 0.7123
epoch : epoch : epoch :	73/100, f 74/100, f 75/100, f	1: 0.5693, 1: 0.5693, 1: 0.5693, 1: 0.5761, 1: 0.5777, 1: 0.5750,	accuracy accuracy accuracy	. 0.9284, .: 0.9285, .: 0.9283, .: 0.9288, .: 0.9295, .: 0.9283,	precision: 0.7123 precision: 0.7195 precision: 0.7062

8x8 با داده های آموزش و تست TVTV با داده های آموزش و تست

## جدول 2. مقايسه نتايج استفاده از روش TVTV

CIFAR10	TVTV		
Dataset resolution	Accuracy	Precision	F1 score
32x32	95.68%	82.45%	76.98%
16x16	94.54%	78.54%	69.61%
8x8	92.83%	70.62%	57.50%

## پاسخ ۲ - آشنایی با معماری CNN

### 2-1. لود دىتاست مقاله

در مقاله "CNN Model for Image Classification on MNIST and Fashion Dataset"، از معماری مختلف برای شبکه CNN معرفی شده است. برای Load کردن دادههای Fashion MNIST، از کتابخانه keras.dataset استفاده می کنیم:

```
!pip install torchmetrics
    import gc
    import torch
    import numpy as np
    import torch.nn as nn
    import matplotlib.pyplot as plt
    import torch.nn.functional as F
    from keras.datasets import fashion_mnist
    from torch.utils.data import DataLoader, Dataset
    from torchmetrics.classification import BinaryF1Score
    from torchmetrics.classification import BinaryAccuracy
    from torchmetrics.classification import BinaryPrecision
Cooking in indexes: https://pypi.org/simple, https://us-python.pkg.dev/colab-wheels/public/simple/
      Downloading torchmetrics-0.10.3-py3-none-any.whl (529 kB)
    | S29 kB 28.5 MB/s | S29 kB 28.5 MB/s | Requirement already satisfied: torch>=1.3.1 in /usr/local/lib/python3.7/dist-packages (from torchmetrics) (1.12.1+cu113)
    Requirement already satisfied: packaging in /usr/local/lib/python3.7/dist-packages (from torchmetrics) (21.3)
    Requirement already satisfied: typing-extensions in /usr/local/lib/python3.7/dist-packages (from torchmetrics) (4.1.1)
Requirement already satisfied: numpy>=1.17.2 in /usr/local/lib/python3.7/dist-packages (from torchmetrics) (1.21.6)
    Requirement already satisfied: pyparsing!=3.0.5,>=2.0.2 in /usr/local/lib/python3.7/dist-packages (from packaging->torchm
    Installing collected packages: torchmetrics
    Successfully installed torchmetrics-0.10.3
```

شكل Import .26 كردن كتابخانه هاى مختلف

بهتر است قبل از اجرای برنامه در Cache ،colab را پاک کنیم:

شکل 27. پاک کردن cache در

سپس دادهها را از کتابخانه keras.dataset، وارد برنامه می کنیم:

```
(x_train, y_train), (x_test, y_test) = fashion_mnist.load_data()
     x_train = torch.tensor(x_train, dtype=torch.float32)
     y_train = torch.tensor(y_train, dtype=torch.float32)
     x_test = torch.tensor(x_test, dtype=torch.float32)
     y_test = torch.tensor(y_test, dtype=torch.float32)
     Downloading data from <a href="https://storage.googleapis.com/tensorflow/tf-keras-datasets/train-labels-idx1-ubyte.gz">https://storage.googleapis.com/tensorflow/tf-keras-datasets/train-labels-idx1-ubyte.gz</a>
                                                          ====] - 0s Ous/step
     Downloading data from https://storage.googleapis.com/tensorflow/tf-keras-datasets/train-images-idx3-ubyte.gz
     26421880/26421880 [==
                                                                    ===] - 2s 0us/step
     Downloading data from <a href="https://storage.googleapis.com/tensorflow/tf-keras-datasets/t10k-labels-idx1-ubyte.gz">https://storage.googleapis.com/tensorflow/tf-keras-datasets/t10k-labels-idx1-ubyte.gz</a>
                                                  ======] - 0s 0us/step
     5148/5148 [==
     Downloading data from <a href="https://storage.googleapis.com/tensorflow/tf-keras-datasets/t10k-images-idx3-ubyte.gz">https://storage.googleapis.com/tensorflow/tf-keras-datasets/t10k-images-idx3-ubyte.gz</a>
     4422102/4422102 [==
                                                              ----] - 0s Ous/step
```

#### شكل Load .28 كردن دادهها

```
class My_Data():
    def __init__(self, x, y, k):
        self.x = x
        self.z = np.zeros((self.x.shape[0], k))
        for i in range(self.x.shape[0]):
            self.z[i][int(y[i])] = 1

    def __len__(self):
        return self.x.shape[0]

    def __getitem__(self, index):
        return self.x[index], self.z[index]
```

شكل 29. تعريف توابع \_\_len\_\_ ، \_\_init\_\_ و \_\_getitem\_\_ و \_\_value \_\_

## 2-2. انتخاب معماري

از مقاله، معماریهای دوم و چهارم را انتخاب می کنیم. Optimum Parameter در معماری دوم و چهارم، 128 droupout ،Adam Optimizer ،softmax چهارم، 128 تایی، تابع فعالسازی 128 است:

```
class CNN_Arc2(nn.Module):
     def __init__(self, K):
        super(CNN_Arc2, self).__init__()
        self.conv1 = nn.Conv2d(1, 64, kernel_size = 2)
        self.conv2 = nn.Conv2d(64, 64, kernel_size = 2)
        self.maxpool = nn.MaxPool2d((2, 2))
        self.dropout = nn.Dropout(p = 0.25)
        self.linear1 = nn.Linear(9216, 64)
        self.linear2 = nn.Linear(64, 10)
      def forward(self, x):
        x = F.softmax(self.conv1(x), dim = 1)
        x = self.maxpool(x)
        x = self.dropout(x)
        x = F.softmax(self.conv2(x), dim = 1)
        x = self.dropout(x)
        x = x.view(x.size(0), -1)
        x=self.linear1(x)
        x = self.dropout(x)
        x = self.linear2(x)
```

### شكل 30. معماري دوم

```
class CNN_Arc4(nn.Module):
  def __init__(self, K):
    super(CNN_Arc4, self).__init__()
    self.conv1 = nn.Conv2d(1, 64, kernel_size = 2)
    self.conv2 = nn.Conv2d(64, 64, kernel_size = 2)
    self.maxpool = nn.MaxPool2d((2, 2))
    self.dropout = nn.Dropout(p = 0.1)
    self.linear1 = nn.Linear(64,64)
    self.linear2 = nn.Linear(64,10)
  def forward(self, x):
    x = F.softmax(self.conv1(x), dim = 1)
    x = self.maxpool(x)
    x = self.dropout(x)
    x = F.softmax(self.conv2(x), dim = 1)
    x = self.maxpool(x)
    x = self.dropout(x)
    x = F.softmax(self.conv2(x), dim = 1)
    x = self.maxpool(x)
    x = self.dropout(x)
    x = F.softmax(self.conv2(x), dim = 1)
    x = self.dropout(x)
    X = X.view(X.size(0), -1)
    x = self.linear1(x)
    x = self.dropout(x)
     x = self.linear2(x)
    return x
```

**شكل 31.** معمارى چهارم

## 2-3 توضيح لايههاي مختلف معماري

معماری دوم، از 3 لایه ساخته شده است. در لایه اول، ورودیها با ابعاد 1x64 از یک فیلتر softmax با سایز کرنل 2x2، عبور می کنند. سپس تابع maxpool، دادهها را به ابعاد 64x64 تبدیل کرده و تابع دوم، دادهها با ابعاد 64x64 از فیلتر softmax عبور می کند و دوباره %25 دادهها را عبور می دهد. در لایه دوم، دادهها با ابعاد 64x64 از فیلتر flat کرده که به و دوباره %25 دادهها با تابع dropout وارد لایه بعدی می شود. در لایه آخر، ورودی ها را flat کرده که به ابعاد 64x10 تبدیل می شود. مجددا %25 این دادهها از تابع dropout عبور کرده و به ابعاد 64x10 در می آید که درواقع به 10 کلاس تقسیم می شود.

معماری چهارم، از 5 لایه ساخته شده است. در لایه اول، ورودیها با ابعاد 1x64 از یک فیلتر معماری چهارم، از 5 لایه ساخته شده است. در لایه اول، ورودیها با ابعاد 64x64 از یک فیلتر 64x64 با سایز کرنل 2x2، عبور می کنند. سپس تابع softmax دادهها با ابعاد 64x64 از فیلتر softmax عبور می دهد. در لایه دوم و سوم، دادهها با ابعاد 25% دادهها با تابع dropout وارد لایه بعدی می شود. در لایه چهارم، دادههای لایه قبلی، از فیلتر softmax عبور کرده و 25% آنها وارد لایه بعدی می شوند. در لایه آخر، ورودیها را flat کرده که به ابعاد 64x64 تبدیل می شود. مجددا 25% این دادهها از تابع dropout عبور کرده و به ابعاد 64x10 در واقع به 10 کلاس تقسیم می شود.

## 2-4. مقایسه نتایج دو معماری مختلف

برای training دادهها، ابتدا دادههای train و test را وارد dataloader می کنیم:

```
train_data = My_Data(x_train, y_train, 10)
test_data = My_Data(x_test, y_test, 10)

train = torch.utils.data.DataLoader(train_data, 128, True)
test = torch.utils.data.DataLoader(test_data, 128, False)
```

شکل 32. وارد کردن دیتاهای train و test به dataloader

تعداد کلاسهای classification و تعداد اپکهای training را از روی optimum parameter مشخص می کنیم:

```
k = len(torch.unique(y_train))
Fashion_MNIST = CNN_Arc2(k)
epochs_number = 50
```

شكل 33. مشخص كردن تعداد كلاسها و اپكها

### Loss Function ،Optimizer، صحت و fl را به تعریف می کنیم:

```
optimizer = torch.optim.Adam(Fashion_MNIST.parameters(), lr = 0.01)
loss_function = nn.CrossEntropyLoss()

f1sc = BinaryF1Score()
acc = BinaryAccuracy()
pre = BinaryPrecision()
softmax = nn.Softmax(dim = 1)

f1score = []
accuracy = []
precision = []
```

شكل 34. معرفي Loss Function ،Optimizer ، دقت، صحت و f1

معماریهای مختلف را وارد GPU می کنیم:

```
device = torch.device('cuda:0' if torch.cuda.is_available() else 'cpu')
loss_function=loss_function.to(device)
Fashion_MNIST.to(device)
acc.to(device)
pre.to(device)
flsc.to(device)
```

شكل 35. واردكردن معماريها به GPU

درنهایت، معماریهای مختلف را train می کنیم:

```
for epoch in range(epochs_number):
  test_loss = []
 Fashion_MNIST.train()
  for data, pred in train:
data = data.unsqueeze(1)
    data = data.to(device)
    pred = pred.to(device)
optimizer.zero_grad()
output = Fashion_MNIST(data)
    loss = loss_function(output.to(device), pred)
    loss.backward()
train_loss.append(loss.item())
    optimizer.step()
 Fashion_MNIST.eval()
  with torch.no_grad():
   for data, pred in test:
    data = data.unsqueeze(1)
       data = data.to(device)
       pred = pred.to(device)
       outputs = Fashion_MNIST(data)
outputs = softmax(outputs)
       los = loss_function(outputs.to(device), pred)
       test_loss.append(los.item())
       accuracy.append(acc(outputs, pred))
 precision.append(pre(outputs, pred))
flscore.append(flsc(outputs, pred))
print(f'epoch {epoch} : Accuracy {sum(accuracy)/len(accuracy)*100} Precision {sum(precision)/len(precision)*100} flscore {sum(flscore)/len
```

شکل Train .36 کردن شبکه

#### دقت، صحت و f1 در معماریهای دوم و چهارم به صورت زیر است:

epoch 0 : Accuracy 97.16773223876953 epoch 1 : Accuracy 97.3185806274414 epoch 2 : Accuracy 97.43936920166016 epoch 3 : Accuracy 97.51832580566406 epoch 4 : Accuracy 97.5419692993164	Precision 87.61808013916016 Precision 88.47347259521484 Precision 88.88602447509766 Precision 89.2293472290039 Precision 89.21279907226562	f1score 85.48558044433594 f1score 86.24827575683594 f1score 86.90110778808594 f1score 87.31656646728516 f1score 87.45767974853516
epoch 5: Accuracy 97.59183502197266	Precision 89.42129516601562	f1score 87.71934509277344
epoch 6: Accuracy 97.62126159667969	Precision 89.53276062011719	f1score 87.87480926513672
epoch 7: Accuracy 97.63480377197266	Precision 89.5618667602539	f1score 87.9498519897461
epoch 8: Accuracy 97.63731384277344	Precision 89.54386901855469	f1score 87.96755981445312
epoch 9: Accuracy 97.62726593017578	Precision 89.45609283447266	f1score 87.92222595214844
epoch 40 : Accuracy 97.70689392089844	Precision 89.52838897705078	f1score 88.37897491455078
epoch 41 : Accuracy 97.71025085449219	Precision 89.53797912597656	f1score 88.39723205566406
epoch 42 : Accuracy 97.71321868896484	Precision 89.54833984375	f1score 88.41303253173828
epoch 43 : Accuracy 97.70460510253906	Precision 89.49769592285156	f1score 88.37044525146484
epoch 44 : Accuracy 97.70934295654297	Precision 89.51594543457031	f1score 88.39525604248047
epoch 45 : Accuracy 97.71381378173828	Precision 89.53571319580078	f1score 88.4184799194336
epoch 46 : Accuracy 97.7154769897461	Precision 89.53936004638672	f1score 88.42778778076172
epoch 47 : Accuracy 97.71257781982422	Precision 89.51643371582031	f1score 88.41439056396484
epoch 48 : Accuracy 97.71275329589844	Precision 89.51060485839844	f1score 88.41654968261719
epoch 49 : Accuracy 97.71359252929688	Precision 89.50965118408203	f1score 88.42169189453125

### شكل 37. دقت، صحت و f1 در معماری دوم با Adam Optimizer

epoch 0 : Accuracy 95.46282196044922	Precision 82.44061279296875	f1score 75.32402801513672
epoch 1 : Accuracy 95.79161834716797	Precision 82.88712310791016	f1score 77.54132080078125
epoch 2 : Accuracy 96.01167297363281	Precision 83.7554702758789	f1score 78.82400512695312
epoch 3 : Accuracy 96.17955780029297	Precision 84.4595718383789	f1score 79.77676391601562
epoch 4 : Accuracy 96.3134994506836	Precision 85.06595611572266	f1score 80.524169921875
epoch 5 : Accuracy 96.41565704345703	Precision 85.5537338256836	f1score 81.08706665039062
epoch 6 : Accuracy 96.49454498291016	Precision 85.9190673828125	f1score 81.52306365966797
epoch 7 : Accuracy 96.54953002929688	Precision 86.23954772949219	f1score 81.81332397460938
epoch 8 : Accuracy 96.60457611083984	Precision 86.42800903320312	f1score 82.13040924072266
epoch 9 : Accuracy 96.64170837402344	Precision 86.5517349243164	f1score 82.34498596191406
epoch 40 : Accuracy 97.06580352783203	Precision 87.93140411376953	f1score 84.77153015136719
epoch 41 : Accuracy 97.07357025146484	Precision 87.9539566040039	f1score 84.81562042236328
epoch 42 : Accuracy 97.07960510253906	Precision 87.9698486328125	f1score 84.85025787353516
epoch 43 : Accuracy 97.08565521240234	Precision 87.98733520507812	f1score 84.88456726074219
epoch 44 : Accuracy 97.08966064453125	Precision 88.00314331054688	f1score 84.90665435791016
epoch 45 : Accuracy 97.09628295898438	Precision 88.02688598632812	f1score 84.94329833984375
epoch 46 : Accuracy 97.10391998291016	Precision 88.04801940917969	f1score 84.98664093017578
epoch 47 : Accuracy 97.1084213256836	Precision 88.05848693847656	f1score 85.0126724243164
epoch 48 : Accuracy 97.1136474609375	Precision 88.08382415771484	f1score 85.0406265258789
epoch 49 : Accuracy 97.11924743652344	Precision 88.09518432617188	f1score 85.07331085205078
		-

## Adam Optimizer شکل 38. دقت، صحت و f1 در معماری چهارم با

```
epoch 0 : Accuracy 90.00006866455078
                                      Precision 0.0
epoch 1 : Accuracy 90.00003814697266
                                      Precision 0.0
                                                     f1score 0.0
epoch 2 : Accuracy 89.99981689453125
                                      Precision 0.0
                                                     f1score 0.0
                                      Precision 0.0
epoch 3 : Accuracy 89.99971771240234
                                                     f1score 0.0
epoch 4 : Accuracy 89.99964904785156
                                      Precision 0.0
                                                     f1score 0.0
epoch 5 : Accuracy 89.99960327148438
                                      Precision 0.0
                                                     f1score 0.0
                                      Precision 0.0
epoch 6 : Accuracy 89.99958038330078
                                                     f1score 0.0
                                    Precision 0.0
epoch 7 : Accuracy 89.99986267089844
                                                     f1score 0.0
epoch 8 : Accuracy 90.0001449584961
                                     Precision 0.0
                                                     f1score 0.0
epoch 9 : Accuracy 90.00038146972656 Precision 0.0 f1score 0.0
```

epoch	40	:	Accuracy	92.85530090332031	Precision 48.23674392700195	f1score 39.178951263427734
epoch	41		Accuracy	92.92776489257812	Precision 49.12368392944336	f1score 40.092952728271484
epoch	42		Accuracy	92.99153137207031	Precision 49.93922424316406	f1score 40.9350471496582
epoch	43		Accuracy	93.0589599609375	Precision 50.770050048828125	f1score 41.77084732055664
epoch	44		Accuracy	93.12336730957031	Precision 51.54970932006836	f1score 42.57292938232422
epoch	45		Accuracy	93.18586730957031	Precision 52.293766021728516	f1score 43.34736633300781
				93.24596405029297	Precision 53.009098052978516	f1score 44.08974838256836
epoch	47		Accuracy	93.30347442626953	Precision 53.69551086425781	f1score 44.800323486328125
epoch	48		Accuracy	93.35865020751953	Precision 54.361026763916016	f1score 45.479827880859375
epoch	49		Accuracy	93.41170501708984	Precision 54.98793029785156	f1score 46.1367073059082

### شکل 39. دقت، صحت و f1 در معماری دوم با SGD Optimizer

```
epoch 0 : Accuracy 90.00006866455078 Precision 0.0
                                                   f1score 0.0
epoch 1 : Accuracy 90.00003814697266
                                    Precision 0.0
                                                   f1score 0.0
epoch 2 : Accuracy 89.99981689453125
                                    Precision 0.0
                                                   f1score 0.0
epoch 3 : Accuracy 89.99971771240234
                                    Precision 0.0
                                                   f1score 0.0
epoch 4 : Accuracy 89.99964904785156
                                    Precision 0.0
                                                   f1score 0.0
epoch 5 : Accuracy 89.99960327148438
                                    Precision 0.0
                                                   f1score 0.0
epoch 6 : Accuracy 89.99958038330078 Precision 0.0
                                                   f1score 0.0
epoch 7 : Accuracy 89.99986267089844 Precision 0.0
                                                   f1score 0.0
epoch 8 : Accuracy 90.0001449584961
                                    Precision 0.0
                                                   f1score 0.0
epoch 9 : Accuracy 90.00038146972656 Precision 0.0
                                                  f1score 0.0
epoch 40 : Accuracy 89.9983139038086
                                        Precision 0.0
                                                         f1score 0.0
epoch 41 : Accuracy 89.99811553955078
                                        Precision 0.0
                                                         f1score 0.0
epoch 42 : Accuracy 89.99793243408203
                                          Precision 0.0
                                                         f1score 0.0
epoch 43 : Accuracy 89.99775695800781
                                          Precision 0.0
epoch 44: Accuracy 89.99759674072266
                                          Precision 0.0
epoch 45 : Accuracy 89.99742889404297
                                          Precision 0.0
                                                           f1score 0.0
epoch 46 : Accuracy 89.99727630615234
                                          Precision 0.0
                                                           f1score 0.0
epoch 47 : Accuracy 89.99712371826172
                                          Precision 0.0
                                                           f1score 0.0
epoch 48 : Accuracy 89.99699401855469
                                          Precision 0.0
                                                           f1score 0.0
epoch 49 : Accuracy 89.99685668945312
                                          Precision 0.0
                                                           f1score 0.0
```

### SGD Optimizer شکل 40. دقت، صحت و 11 در معماری چهارم با

## 2-5 مقایسه نتایج استفاده از بهینهسازهای مختلف

### جدول 3. مقایسه نتایج استفاده از بهینهسازهای مختلف در معماریهای مختلف

Architectures	Optimizer	Accuracy	Precision	F1score
2th	Adam	97.71%	89.50%	88.42%
201	SGD	93.41%	54.98%	45.13%
4th	Adam	97.11%	88.09%	85.07%
Tui	SGD	89.99%	0%	0%

## 2-6. استفاده از Dropout

در هنگام آموزش، برخی از نورونها را رها میشود تا از Overfit شدن شبکه، جلوگیری شود. با رها کردن اتفاقی برخی نورونها در شبکه، در هر ایک، نورونهای متفاوتی در شبکه train میشود اما همه نورونها در test وجود دارد و این سبب میشود شبکه دیرتر Overfit شود.